



Big Data y Machine Learning

Posgrado de Técnicas para la
Digitalización en la Industria

Sesión 4 – Aprendizaje no supervisado

Marc Jené: marc.jene@upc.edu



Calendario

	Lunes	Martes	Miércoles	Jueves
Marzo	17 S1 – Introducción a Big Data y Machine Learning	18	19 S2 – Introducción a Python	20
	24 S3 – Estadística descriptiva	25	26 S4 – Modelos de aprendizaje no supervisado	27
Abril	31 S7 – Modelos de aprendizaje supervisado (II): Regresión	1	2 S6 – Image Recognition y IA de la nueva generación	3
	6 S5 – Modelos de aprendizaje supervisado (I): Clasificación	7	8 S8 – Exámen	9





Objetivos de la sesión

- Diferenciar el aprendizaje **Supervisado** y **No Supervisado**.
- Conocer los algoritmos utilizados en **Aprendizaje No Supervisado**.
- **Aplicaciones** del clustering.
- **Métricas** para encontrar el número óptimo de clusters.
- Jupyter Notebook.



Diferenciar el aprendizaje Supervisado y No Supervisado.

Algoritmos utilizados en Aprendizaje No Supervisado.

Métricas para encontrar el número óptimo de clusters.

Aplicaciones del clustering.

Reducción de dimensiones.



Recapitulemos...

MACHINE LEARNING

Aprendizaje
Supervisado

Regresión

Clasificación

Aprendizaje NO
Supervisado

Clustering

Reducir dimensiones

Reinforcement
Learning



Principales diferencias entre aprendizaje supervisado y NO supervisado

Aprendizaje Supervisado

Aprendizaje NO Supervisado

Datos de entrada

Hay datos etiquetados (target)

No hay datos etiquetados
(**no** target)

Objetivo


Realizar predicciones de
clasificación/regresión.

Encontrar patrones ocultos en
los datos.
Reducir dimensiones




¿Qué es el aprendizaje NO supervisado?

El objetivo es entrenar un modelo para **encontrar patrones** en un conjunto de datos sin etiqueta.






¿Qué es el aprendizaje NO supervisado?






¿Qué es el aprendizaje NO supervisado?

UNSUPERVISED



SUPERVISED





Introducción al aprendizaje no supervisado

¿Qué abarca el aprendizaje no supervisado?

Clustering

- Algoritmos de partición (K-means).
- Algoritmos basados en la jerarquía (Hierarchical).
- Algoritmos basados en la densidad (density).

Reducción de dimensiones (Análisis de componentes principales (PCA))



Diferenciar el aprendizaje Supervisado y No Supervisado.

Algoritmos utilizados en Aprendizaje No Supervisado.

Métricas para encontrar el número óptimo de clusters.

Aplicaciones del clustering.

Reducción de dimensiones.



Introducción al aprendizaje no supervisado

¿Qué abarca el aprendizaje no supervisado?

Clustering

- Algoritmos de partición (K-means).
- Algoritmos basados en la jerarquía (Hierarchical).
- Algoritmos basados en la densidad (density).

Reducción de dimensiones (Análisis de componentes principales (PCA))



Clustering


Objetivo: agrupar personas o elementos basándonos en sus características.

Definición: Es la tarea de dividir el conjunto de datos de entrada (dataset) en varios grupos, de manera que los datos que pertenecen a un mismo grupo sean parecidos entre ellos y diferentes de los datos de otros grupos.

- Sirve para comprender la estructura de los datos, o como preprocesamiento para el aprendizaje supervisado (por ejemplo entrenar un clasificador para cada grupo).
- El clústering no necesita etiquetas, que suelen ser costosas de obtener.



sample




Cluster/group



Algoritmos de Clustering


Algoritmos de partición

- **K-means**
- Este algoritmo divide las observaciones en ***k clusters*** (grupos) y cada partición forma un cluster.




Algoritmos basados en la jerarquía

- **Hierarchical Clustering**
- Los cúmulos forman una estructura tipo árbol basada en la jerarquía.
- Se divide en dos categorías:
 - **Aglomerado**
 - **Divisivo**



Algoritmos basados en la densidad


- **DBSCAN, OPTICS**
- Estos algoritmos consideran que los clusters son una región densa que tiene cierta similitud y son diferentes de la región más baja y densa del espacio.





Método de partición: K-means

- Agrupa las observaciones en k clusters (el valor de K debe ser especificado previamente).
- El algoritmo k-means hace lo siguiente:
 - Determina de forma iterativa los mejores puntos centrales K (conocidos como **centroides**).
 - Asigna cada observación al centroide más cercano. Los ejemplos más cercanos al mismo centroide pertenecen al mismo grupo.
- El algoritmo k-means selecciona las ubicaciones del centroide para minimizar el cuadrado acumulativo de las distancias desde cada ejemplo hasta su centroide más cercano.






Método de partición: K-means

Pasos a seguir

- Para **K** número de clusters, elige un centroide al azar.
- Calcula la distancia a los otros puntos del centroide.
- Ajustar el centroide iterativamente, y asigna cada punto de datos al centroide más cercano.
- Continúa ajustando hasta que el centroide no se mueva.






Método jerárquico: clustering jerárquico

El algoritmo de clúster jerárquico agrupa los datos basándose en la distancia entre cada uno y buscando que los datos que están dentro de un clúster sean los más similares entre sí.

Tipos de clustering jerárquico dependiendo de la dirección en la que el algoritmo ejecute el agrupamiento:


- **Tipo Aglomerativo:** Empezamos a agrupar desde cada elemento individual. Al inicio cada punto o dato está en un clúster separado. A cada paso, los dos clústers más cercanos se fusionan. Al final del proceso solo queda un único clúster que aglutina todos los elementos.
- **Divisible:** Comenzamos a la inversa, partimos de un único clúster que aglomera todos los datos y vamos dividiendo en clústers más pequeños.

Dendograma: manera de representar un clustering jerárquico.







Método jerárquico: clustering jerárquico






Método jerárquico: clustering jerárquico






Método jerárquico: clustering jerárquico divisible






Método basado en la densidad

- Un clúster en una región densa de puntos, separada por regiones poco densas de otras regiones densas.
- Útiles cuando los clusters tienen formas irregulares, están entrelazados o hay ruido/outliers en los datos. Se elimina el ruido del conjunto de datos.
- Algoritmo basado en densidad: **DBSCAN** (Density Based Spatial Clustering of Applications with Noise)





Método basado en la densidad





Método basado en la densidad: DBSCAN


DBSCAN: Detecta regiones densas de puntos separadas de otras regiones densas por regiones poco densas

Densidad: Número de puntos en un radio específico

Dataset



DBSCAN Clustering




core (1 cluster) **border** (frontera) **noise** (ruido)



Comparación de algoritmos de clustering

MÉTODO CLUSTERING	APLICACIÓN	MÉTRICA UTILIZADA
K-means	• Uso general • Tamaño de cluster uniforme y de geometría plana • No demasiados clusters.	Distancia entre puntos
Hierarchical clustering	• Muchos clusters • Distancias no euclidianas	Cualquier distancia por pares
DBSCAN	• Geometría no plana • Tamaños desiguales de clusters • Detección de outliers	Las distancias entre los puntos más cercanos



<https://scikit-learn.org/stable/modules/clustering.html#clustering>



Diferenciar el aprendizaje Supervisado y No Supervisado.

Algoritmos utilizados en Aprendizaje No Supervisado.

Métricas para encontrar el número óptimo de clusters.

Aplicaciones del clustering.

Reducción de dimensiones.




*En el aprendizaje no supervisado no existe una cuantificación del error como tal entre el resultado del modelo de clustering y el valor verdadero, ya **que el valor verdadero es desconocido**. Se utilizarán métodos para estimar el número óptimo k de clusters.*



Métrica de evaluación

Método Elbow

- El método Elbow nos da una idea del número óptimo de **K** de clusters.
- Se basa en la suma de la distancia al cuadrado entre los puntos de datos y los **centroides** de los clústers asignados.





$$Inercia = \sum_{i=0}^N \|x_i - \mu\|^2$$



Métrica de evaluación

Método Elbow





Métrica de evaluación

Coeficiente Silhouette


- Esta métrica de evaluación puede utilizarse para determinar el grado de separación entre los clusters/grupos.

a(i) es la distancia promedio de todos los puntos de datos en el mismo cúmulo

b(i) es la distancia promedio de todos los puntos de datos en el cúmulo más cercano.

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

- El coeficiente puede tomar valores en el intervalo [-1, 1].
 - 0:** la muestra está muy cerca de los clusters vecinos.
 - 1:** la muestra está muy lejos de los clusters vecinos.
 - 1:** la muestra está asignada a los clusters equivocados.






Métrica de evaluación

Coeficiente Silhouette

- Queremos que los coeficientes sean lo más grandes posibles y que estén cerca de 1 para tener un buen cluster.



Número óptimo de clusters: **k=5**



Diferenciar el aprendizaje Supervisado y No Supervisado.

Algoritmos utilizados en Aprendizaje No Supervisado.

Métricas para encontrar el número óptimo de clusters.


Aplicaciones del clustering.

Reducción de dimensiones.



Aplicaciones del Clustering - Genérico


Márketing: Segmentación de clientes





Aplicaciones del Clustering - Genérico


Elaboración de gráficos





Aplicaciones del Clustering - Genérico


Biología: clasificación de plantas y animales según sus características.






Aplicaciones del Clustering - Genérico

Comunidades de redes sociales



<https://griffsgraphs.wordpress.com/tag/social-network/>




<http://social-dynamics.org/gephi-facebook/>



Aplicaciones del Clustering - Genérico

Genética







Aplicaciones del Clustering – Mecatrónica e Industria 4.0

Mantenimiento predictivo

Agrupar patrones de vibración, temperatura o consumo eléctrico de motores y maquinaria para detectar comportamientos fuera de lo común (anomalías). Sobre todo cuando no tenemos referencia de qué valores se consideran anomalías.







Aplicaciones del Clustering – Mecatrónica e Industria 4.0

Control de calidad

Agrupar muestras de productos con base en múltiples características medidas durante el control de calidad para identificar grupos homogéneos (y detectar posibles lotes defectuosos).

Por ejemplo, se puede hacer clustering de señales obtenidos a través de sensores ópticos en una línea de inspección para clasificar defectos en piezas.



Outliers/Anomalies got isolated earlier (here, at split 2). The normal points got isolated much later – at split 4 here

<https://medium.com/data-science/anomaly-detection-in-python-part-2-multivariate-unsupervised-methods-and-code-b311a63f298b>




Aplicaciones del Clustering – Mecatrónica e Indústria 4.0

Identificar perfiles de conductores de EVs

Agrupar usuarios permite adaptar la infraestructura de carga, diseñar estrategias de gestión energética y mejorar la experiencia de usuario.

Podemos detectar los usuarios que cargan el vehículo cada noche, los que solo lo usan durante el fin de semana (o al revés), los taxistas / conductores de Uber, etc. y ofrecer servicios para cada tipo de usuario.





Diferenciar el aprendizaje Supervisado y No Supervisado.

Algoritmos utilizados en Aprendizaje No Supervisado.

Métricas para encontrar el número óptimo de clusters.

Aplicaciones del clustering.

Reducción de dimensiones.



Introducción al aprendizaje no supervisado

¿Qué abarca el aprendizaje no supervisado?

Clustering


- Algoritmos de partición (K-means).
- Algoritmos basados en la jerarquía (Hierarchical).
- Algoritmos basados en la densidad (density).

Reducción de dimensiones (Análisis de componentes principales (PCA))



Reducción de dimensiones: principal component analysis (PCA)

- El **análisis de componentes principales** es uno de los algoritmos de **selección de características** (feature selection) más habituales.
- Se usa para reducir la “dimensión” de los datos. Con dimensión nos referimos al “número de variables”.



- Pasamos de 5 características a 2.
- Las 2 columnas capturan la mayoría de la información de las 5 columnas anteriores.
- El resultado indica que no se pierde mucha información y el dataset (matriz X) se simplifica bastante.



Reducción de dimensiones: principal component analysis (PCA)

Ejemplo. Pasamos de 3 dimensiones a 2 dimensiones utilizando PCA.

```
from sklearn.decomposition import PCA
```

```
>>> import numpy as np
>>> from sklearn.decomposition import PCA
>>> X = np.array([[ -1, -1], [-2, -1], [-3, -2], [ 1,  1], [ 2,  1], [ 3,  2]])
>>> pca = PCA(n_components=2)
>>> pca.fit(X)
```

