



# Tecnologías Aplicadas a la Mecatrónica 4.0

Introducción a Big Data y Machine Learning

## Sesión 5 - Modelos de Aprendizaje Supervisado - Regresión

Antonio Emmanuel Saldaña González  
[antonio.emmanuel.saldana@upc.edu](mailto:antonio.emmanuel.saldana@upc.edu)



# Información Personal

- **Nombre:** Antonio E Saldaña González



[www.linkedin.com/in/antonio-saldaña-070b79197](https://www.linkedin.com/in/antonio-saldaña-070b79197)

- **Centro:** CITCEA-UPC (ETSEIB)
- **Email:** [antonio.emmanuel.saldana@upc.edu](mailto:antonio.emmanuel.saldana@upc.edu)
- Oficina 23.27 Pavelló G, ETSEIB – Departamento de Ingeniería Eléctrica.
- **Campos de investigación:** Planificación de redes de distribución, Integración óptima de renovables y vehiculos eléctricos, modelos supervisados para predicción de energía e inversiones.



|       | Lunes                                                            | Martes | Miércoles                                                 | Jueves |
|-------|------------------------------------------------------------------|--------|-----------------------------------------------------------|--------|
| Marzo | 17<br>S1 – Introducción a Big Data y Machine Learning            | 18     | 19<br>S2 – Introducción a Python                          | 20     |
|       | 24<br>S3 – Estadística descriptiva                               | 25     | 26<br>S4 – Modelos de aprendizaje no supervisado y repaso | 27     |
| Abril | 31<br>S5 – Modelos de aprendizaje supervisado (I): Regresión     | 1      | 2<br>S6 – Image Recognition y IA de la nueva generación   | 3      |
|       | 6<br>S7 – Modelos de aprendizaje supervisado (II): Clasificación | 7      | 8<br>S8 – Exámen                                          | 9      |

Sesión Online

Sesión Presencial




## Objetivos generales de la sesión

- Comprender fundamentos y aplicaciones de Aprendizaje Supervisado
- Diferenciar entre regresión y clasificación
- Conocer algunos modelos supervisados existentes
- Entrenar un modelo de aprendizaje automático de regresión
- Validar y evaluar el modelo de aprendizaje automático



## Contenidos de la sesión

- ¿Que es el aprendizaje supervisado? ¿Aplicaciones?
- Regresión Lineal con librería Scikit-learn
- Modelos de regresión existentes
- Creación y evaluación de modelos de regresión (Jupyter)
- Visualización en Jupyter





## **Actividad 1: Quiz**

Kahoot:

<https://create.kahoot.it/details/5fd4f32b-f798-48bd-a947-717162d50abc>



## MACHINE LEARNING

Aprendizaje  
Supervisado

Regresión

Clasificación

Aprendizaje NO  
Supervisado

Clustering

Reducir dimensiones

Reinforcement  
Learning



## Principales diferencias entre aprendizaje supervisado y NO supervisado

### Aprendizaje Supervisado

- Hay datos etiquetados (target)
- Realizar predicciones de clasificación/regresión.

### Aprendizaje no Supervisado

- **No hay** datos etiquetados (No existe un target)
- Encontrar patrones ocultos en los datos. Clustering (k-means, Hierarchical)
- Reducir dimensiones (Principal Component Analysis)

Datos de entrada


Objetivo





## ¿Qué es el aprendizaje supervisado?



El objetivo es entrenar un modelo para **encontrar patrones** en un conjunto de datos **con etiqueta**.





## Aplicaciones de Aprendizaje Supervisado


- Clasificación de Tumores Malignos y Benignos
- Predicción de Ingresos
- Predecir la generación de fotovoltaica





## Detectar correos spam

Conjunto de entrenamiento que introducimos en el modelo incluyen las soluciones deseadas denominadas etiquetas.




Clasificación de Correos Spam



## Predicir precio de un coche

- Predicción de precio de un coche a partir de un conjuntos de características o atributos (Kilometraje, Año, Marca, etc.)
- Predicción múltiples entrada una salida , una entrada y una salida.
- Algunos modelos de regresión pueden usarse para la clasificación y viceversa.






## Generalización de Modelos Supervisados

- Un modelo con una cantidad de datos de entrenamiento tiene que ser capaz de hacer predicción incluso para ejemplos que nunca ha visto antes.
- Tener buenas métricas en el entrenamiento está bien, pero no es suficiente, el verdadero objetivo es tener buen rendimiento en instancias nuevas.

### Ejemplo 1:


Table 1-1. Does money make people happier?

| Country       | GDP per capita (USD) | Life satisfaction |
|---------------|----------------------|-------------------|
| Turkey        | 28,384               | 5.5               |
| Hungary       | 31,008               | 5.6               |
| France        | 42,026               | 6.5               |
| United States | 60,236               | 6.9               |
| New Zealand   | 42,404               | 7.3               |
| Australia     | 48,698               | 7.3               |
| Denmark       | 55,938               | 7.6               |





- **Modelo regresión lineal:** Introducimos datos de entrenamiento a nuestro modelo lineal seleccionado, con el objetivo de encontrar los parámetros que mejor se ajustan a nuestros datos.



**Nota:** El modelo en este primer ejemplo muestra un buen ajuste global de los datos.



## ¿Cómo iniciar a entrenar el ejemplo 1 con un Modelo Lineal y datos reales?

```
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
from sklearn.linear_model import LinearRegression

# Download and prepare the data
data_root = "https://github.com/ageron/data/raw/main/"
lifesat = pd.read_csv(data_root + "lifesat/lifesat.csv")
X = lifesat[["GDP per capita (USD)"]].values
y = lifesat[["Life satisfaction"]].values

# Visualize the data
lifesat.plot(kind='scatter', grid=True,
             x="GDP per capita (USD)", y="Life satisfaction")
plt.axis([23_500, 62_500, 4, 9])
plt.show()

# Select a linear model
model = LinearRegression()

# Train the model
model.fit(X, y)

# Make a prediction for Cyprus
X_new = [[37_655.2]] # Cyprus' GDP per capita in 2020
print(model.predict(X_new)) # output: [[6.30165767]]
```



**Nota:** Se puede cambiar el modelo de entrenamiento fácilmente!



```
from sklearn.linear_model import LinearRegression
model = LinearRegression()

with these two:

from sklearn.neighbors import KNeighborsRegressor
model = KNeighborsRegressor(n_neighbors=3)
```






## Retos comunes en ajustes de modelos supervisados

- 1. Cantidad insuficiente de datos:** Se necesitan de miles o millones de datos para tener muchas veces un modelo robusto y generalizado para diversos escenarios.
- 2. Datos de entrenamiento no representativos:** Una mala generalización omite datos representativos en el entrenamiento.

¿Qué pasaría si quisiéramos predecir valores fuera de rango? ¿Sería válido nuestro modelo de regresión lineal?









## Retos comunes en ajustes de modelos supervisados

**3. Datos de mala calidad:** Errores, valores atípicos y ruido pueden presentarse en los datos que deseamos usar para entrenar nuestros modelos.

*Tip 1:* Tratamiento de datos faltantes (técnicas de media, mediana, etc.)

*Tip 2:* Descartar valores atípicos que puedan interferir en el entrenamiento de datos.





## Retos comunes en ajustes de modelos supervisados

**4. Selección de características o atributos relevantes:** Seleccionar características útiles con las que entrenar un modelo.

*Tip 1:* Extraer las características importantes (Matriz de correlación, técnicas de reducción de la dimensionalidad, etc.)

*Tip 2:* Crear nuevas características en caso de no ser muy relevantes con datos nuevos.

|       |       |       |       |       |       |
|-------|-------|-------|-------|-------|-------|
| INDUS | 1.00  | -0.39 | -0.71 | 0.60  | -0.48 |
| RM    | -0.39 | 1.00  | 0.21  | -0.61 | 0.70  |
| DIS   | -0.71 | 0.21  | 1.00  | -0.50 | 0.25  |
| LSTAT | 0.60  | -0.61 | -0.50 | 1.00  | -0.74 |
| MEDV  | -0.48 | 0.70  | 0.25  | -0.74 | 1.00  |
|       | INDUS | RM    | DIS   | LSTAT | MEDV  |






## Retos comunes en ajustes de modelos supervisados

**5. Sobreajustar datos de entrenamiento:** Los modelos complejos (Redes Neuronales) pueden tener sobreajuste de modelos los cuales son poco fiables.

*Tip 1:* Iniciar con modelos sencillos. Aplicar modelos que se adapten a la complejidad de los datos.





- Regularización reduce el riesgo de hacer sobreajuste, esto se controla en los hiperparámetros.
- Usar una muestra representativa y modelo sencillo es la mejor opción si estas empezando a usar modelos supervisados.





Figure 1-24. Regularization reduces the risk of overfitting



## Pasos para aplicar modelos supervisados





## Modelos Existentes

**Scikit Learn ofrece varios modelos de regresión**

- Support Vector Machine
- Nearest Neighbors regression
- Gaussian Process regression
- Decision trees
- Random Forest
- Ensemble Methods
- Linear regression
- Ridge regression
- Bayesian regression
- Generalized linear regression
- Quantile regression



**También existen otros modelos de otras librerías**

- Redes Neuronales
- XGboost





**¿Cuál modelo tengo que usar?**









## ¿Cuál modelo tengo que usar?

- Teorema “No free lunch”



*No existe un algoritmo óptimo universal para todos los problemas de optimización.*







## Pasos para seleccionar el mejor modelo supervisado

Una práctica común es evaluar diversos modelos candidatos a una predicción y seleccionar el mejor basado en el que obtenga el mejor rendimiento.




Figure 1-25. Model selection using holdout validation



## Seleccionar una medida de rendimiento

**Raíz de Error Medio Cuadrático (RECM, en inglés RMSE):** Es una medida de rendimiento típica para los problemas de regresión es la raíz de error medio cuadrático (RMSE), que da una idea de qué nivel de error tienen las predicciones del modelo, dándoles un peso mayor a los errores grandes.

$$\text{RMSE}(\mathbf{X}, h) = \sqrt{\frac{1}{m} \sum_{i=1}^m \left( h(\mathbf{x}^{(i)}) - y^{(i)} \right)^2}$$




**Error Absoluto Medio (EAM, en inglés MAE):** Es conveniente usar esta métrica cuando existen muchos valores atípicos.


$$\text{MAE}(\mathbf{X}, h) = \frac{1}{m} \sum_{i=1}^m \left| h(\mathbf{x}^{(i)}) - y^{(i)} \right|$$



## ¿Cómo mejorar mi manera de escoger?

- Experiencia
- Conocimiento sobre los modelos





- Sitios con datos open Access:
  - [OpenML.org](https://openml.org)
  - [Kaggle.com](https://kaggle.com)
  - [PapersWithCode.com](https://paperswithcode.com)
  - [UC Irvine Machine Learning Repository](https://machinelearningrepository.org)
  - [Amazon's AWS datasets](https://aws.amazon.com/datasets)
  - [TensorFlow datasets](https://tfhub.dev)
- Meta portals (they list open data repositories):
  - [DataPortals.org](https://dataportals.org)
  - [OpenDataMonitor.eu](https://opendatamonitor.eu)
- Other pages listing many popular open data repositories:
  - [Wikipedia's list of machine learning datasets](https://en.wikipedia.org/wiki/List_of_machine_learning_datasets)
  - [Quora.com](https://www.quora.com)
  - [The datasets subreddit](https://www.reddit.com/r/datasets)



## Repositorio de GitHub del Módulo Big Data y Machine Learning

<https://github.com/marcjene/Mecatronica-BDyML-2425>

