



Tecnologías Aplicadas a la Mecatrónica 4.0

Introducción a Big Data y Machine Learning

Sesión 7 – Modelos de Aprendizaje Supervisado (I): Clasificación

Antonio E Saldaña: antonio.emmanuel.saldana@upc.edu



Calendario

	Lunes	Martes	Miércoles	Jueves
Marzo	17 S1 – Introducción a Big Data y Machine Learning	18	19 S2 – Introducción a Python	20
	24 S3 – Estadística descriptiva	25	26 S4 – Modelos de aprendizaje no supervisado y repaso	27
Abril	31 S5 – Modelos de aprendizaje supervisado (I): Clasificación	1	2 S6 – Image Recognition y IA de la nueva generación	3
	7 S7 – Modelos de aprendizaje supervisado (II): Regresión	8	9 S8 – Exámen	10



Objetivos de la sesión

- Glosario de Términos
- Recapitulemos Supervised Learning: Regresión
- ¿Qué es la clasificación?
- Ejemplos de aplicaciones.
- Detectar y resolver el desequilibrio de clases.
- Principales modelos de clasificación.
- Métricas de evaluación de la clasificación.
- Presentación de un ejemplo práctico de un modelo de clasificación.




Glosario de Términos

- **Muestra:** Un caso individual del conjunto de datos.
- **Atributo/Característica/Feature:** Una propiedad que describe una característica de una muestra. También es una variable de entrada usada por el modelo para aprender.
- **Etiqueta/Variable objetivo/Label:** Valor que el modelo debe predecir (la salida esperada).
- **Clases:** Son todas las categorías posibles. Conjunto del total de etiquetas.
- **Vector de características:** Conjunto de valores que describen una muestra.
- **Variable independiente (Atributo/Feature):** Característica utilizada como entrada
- **Variable dependiente (Etiqueta/salida):** Lo que el modelo intenta predecir.



Resumen...

El objetivo es entrenar un modelo supervisado en un conjunto de datos con características con etiqueta.







Recapitulemos...

Aprendizaje Supervisado

Regresión




Clasificación





¿Qué es clasificación en Machine Learning?

El objetivo de la clasificación es predecir una **clase categórica** basada en un conjunto de características/atributos y observaciones pasadas.





Media saying AI will
take over the world




My Neural Network



AI will take over soon



Clasificación de variables



Es necesario codificar las variables no numéricas para presentarlas como números.



¿Qué es una clase categórica?

Una clase categórica es una etiqueta o categoría que representa una posible salida en un problema de clasificación. No tiene un valor cuantitativo, solo indica pertenencia a un grupo.

Ejemplos:

- Clasificación binaria: [“positivo”, “negativo”]
- Multiclase: [“perro”, “gato”, “ratón”]

Estas clases se suelen codificar en números (por ejemplo, con *label encoding* o *one-hot encoding*) para ser procesadas por los algoritmos.



¿Cómo pasar de variables cualitativas a numéricas?

Los modelos de Machine Learning requieren que todas las variables de entrada y salida sean **numéricas**.

Datos de entrada

ID	Country	Population
1	Japan	127185332
2	U.S	326766748
3	India	1354051854
4	China	1415045928
5	U.S	326766748
6	India	1354051854

Datos no numéricos

[Más información](#)

• LABEL ENCODER

ID	Country	Population
1	0	127185332
2	1	326766748
3	2	1354051854
4	3	1415045928
5	1	326766748
6	2	1354051854

El problema aquí es que como hay diferentes números en la misma columna, el modelo malinterpretará los datos y supondrá que existe algún tipo de orden, $0 < 1 < 2$.

• ONE HOT ENCODING

ID	Country_Japan	Country_U.S	Country_India	Country_China	Population
1	1	0	0	0	127185332
2	0	1	0	0	326766748
3	0	0	1	0	1354051854
4	0	0	0	1	1415045928
5	0	1	0	0	326766748
6	0	0	1	0	1354051854



Conceptos generales.

Tipos de Clasificación.

Aplicaciones de Clasificación.

Detectar y resolver el desequilibrio de clases.

Principales modelos de Clasificación.

Métricas de evaluación: Clasificación.

Ejemplo práctico de un modelo de Clasificación.



Tipos de Clasificación

CLASIFICACIÓN BINARIA

- Solo se pueden asignar dos clases diferentes (**0 o 1**).

CLASIFICACIÓN MULTI-CLASE

- Cada muestra sólo puede ser etiquetada como una clase.
- Ejemplo: Clasificar un tipo de fruta en una imagen.
- Clases: [“manzana”, “banana”, “naranja”]

CLASIFICACIÓN MULTI-ETIQUETA

- Cada muestra puede tener más de una clase a la vez.

Ejemplo: Etiquetar los temas de un artículo científico.


Clases: [“política”, “salud”, “tecnología”, “educación”]

Un artículo puede tener varias etiquetas (p. ej. [“salud”, “tecnología”])

TIPOS DE CLASIFICACIÓN	NÚMERO DE ETIQUETAS DIFERENTES POR CLASE	NÚMERO DE ETIQUETAS A PREDECIR
Clasif. binaria	2	1
Clasif. multi-clase	≥ 2	1
Clasif. multi-etiqueta	≥ 2	≥ 2



Multi-Class vs Multi-Etiqueta



One hot encoding



Conceptos generales.

Tipos de Clasificación.

Aplicaciones de Clasificación.

Detectar y resolver el desequilibrio de clases.

Principales modelos de Clasificación.

Métricas de evaluación: Clasificación.

Ejemplo práctico de un modelo de Clasificación.



Aplicaciones clasificación

APLICACIONES CLASIFICACIÓN BINARIA

- Detección de spam (“spam” o “no spam”)

Las tareas de clasificación binaria implican una clase que es el **estado normal** (etiqueta de clase 0) y otra clase que es el **estado inusual** (etiqueta de clase 1).

Estado inusual (spam)

Estado normal (no spam)

Estado normal (no spam)



INBOX



“no spam”
Clase 0

SPAM FOLDER



“spam”
Clase 1



Aplicaciones clasificación

APLICACIONES CLASIFICACIÓN BINARIA

- Covid detection (“COVID-19” or “non-COVID-19”)




Figure 1: Block Diagram Describing Procedure of Identification of Covid19 using GLCM Feature Extraction Method



Aplicaciones clasificación

APLICACIONES CLASIFICACIÓN MULTI-CLASE

- Clasificación de las especies de plantas
- Reconocimiento óptico de caracteres

Más de **10.000** especies de plantas diferentes



PICTURE THIS

<https://www.picturethisai.com/>



Diagnóstico automático de problemas

Haz una foto de las partes enfermas de una planta para conseguir las causas del problemas y sugerencias de tratamiento.



Identifica plantas con una foto



Solo tienes que hacer o subir una foto de una planta para conseguir resultados de identificación de la planta precisos e instantáneos gracias a nuestra revolucionaria tecnología de inteligencia artificial.



Aplicaciones clasificación

APLICACIONES CLASIFICACIÓN MULTI-CLASE

- Clasificación de las especies de plantas
- **Reconocimiento óptico de caracteres**




Reconocimiento óptico de caracteres



Aplicaciones clasificación

APLICACIONES CLASIFICACIÓN MULTI-ETIQUETA

- **Reconocimiento** de múltiples objetos conocidos en una fotografía (bicicleta, manzana, persona...).





Aplicaciones clasificación

APLICACIONES CLASIFICACIÓN MULTI-ETIQUETA

- **Clasificación de noticias:** un artículo puede ser sobre **deportes**, una **persona** y un **lugar** al mismo tiempo.

Table 1. Class label of Indonesian new

Class Label	Explanation
1	Politic
2	Law
3	Economy
4	Social
5	Culture
6	Technology
7	Life Style
8	Sport
9	Entertainment
10	Education
11	Defense
12	Health
13	Others

Table 2. Dataset of Indonesian news and label.

No	News Article	Class Label
1	The dynamics of dismantling the 2019 presidential candidate pair continues. Whoever is a floating figure can be juxtaposed. Moreover, a number of continually emerging are considered alternative candidates.	1
2	Today (30/11) Butet Kartaredjasa will present 138 visual works at the exhibition at the National Gallery Jakarta. The visual work takes the painted media. This way of art is deliberately done by Butet to conduct social criticism of the community and the government.	5,9
3	The Vice President of the Republic of Indonesia, Jusuf Kalla delivered a written warning to the Minister of Youth and Sports Imam Nahrawi to allocate more funds to prepare for a number of sports ahead of the 2018 Asian Games.	1,3,8



Conceptos generales.

Tipos de Clasificación.

Aplicaciones de Clasificación.

Detectar y resolver el desequilibrio de clases.

Principales modelos de Clasificación.

Métricas de evaluación: Clasificación.

Ejemplo práctico de un modelo de Clasificación.



Desequilibrio de clases

DESEQUILIBRIO ENTRE CLASES: sucede cuando las observaciones (datos de entranamiento) no se encuentran balanceadas. El modelo predecirá peor la etiqueta con menos observaciones al tener menos instancias con las que entrenar.



SOLUCIONES

- **Conseguir más datos** (si es posible).
- **Sobre-muestreo (over-sampling):** duplicación de las observaciones de la clase minoritaria.
- **Sub-muestreo (under-sampling):** eliminación de datos de clase mayoritaria.
- Cambiar la **métrica de evaluación**.
- Generar **datos sintéticos** de la clase minoritaria.
- **StratifiedShuffleSplit()**

EJEMPLOS

- Detección de fraude energético.

Referencia: [8 Tactics to Combat Imbalanced Classes in Your Machine Learning Dataset](#)



Ejemplo

Underfitting

Entreno al modelo con
1 sólo raza de perro



La máquina fallará en reconocer al perro por falta de suficientes muestras. No puede generalizar el conocimiento.

Muestra nueva:
¿Es perro?



NO
FALLO


Overfitting

Entreno al modelo con
10 razas de perro color marrón



La máquina fallará en reconocer un perro nuevo porque no tiene estrictamente los mismos valores de las muestras de entrenamiento.

Muestra nueva:
¿Es perro?



NO
FALLO

Prevenir el sobre-ajuste de datos:


- Cantidad mínima de muestras para entrenar y validar el modelo
- Clases variadas y equilibradas en cantidad, es importante que los datos de entrenamiento estén balanceados.
- Ajuste de parámetros, deberemos experimentar sobre todo dando más/menos “tiempo/iteraciones” al entrenamiento.




Construir un clasificador preciso

Para un buen rendimiento del **test**, es necesario:


- Suficientes datos de **entreno** (así se evita el *underfitting*).
- Obtener un buen resultado de los datos de **entrenamiento**.
- El clasificador no debe ser demasiado "complejo" (así se evita el *overfitting*).



Insuficientes
datos de entreno



Error de entreno
demasiado alto



Clasificador
demasiado complejo.

Ejemplo 1: IRIS en Jupyter

El conjunto de datos contiene 3 clases, donde cada clase se refiere a un tipo de planta de iris. El número total de muestras son 150 (divididas en 50 para cada clase), las cuales contienen 4 atributos diferentes.

Objetivo: Entrenar un modelo con los inputs (atributos) y los outputs (clases), para que aprenda a reconocer el tipo de planta.

Planta	Longitud Sépalo	Anchura del Sépalo	Longitud Pétalo	Ancho de Pétalo	Tipo de Iris
1	4.3	2	1	0.1	Setosa
2	7.9	4.4	6.9	2.5	Versicolor
3	5.84	3.05	3.76	1.2	Verginica
4	0.83	0.43	1.76	0.76	Setosa
...	...	...	...	...	...
150	3.5	3.95	1.56	2.61	Versicolor




Iris - Setosa



Iris - Versicolor




Iris - Verginica





Pasos para aplicar modelos supervisados





Conceptos generales.

Tipos de Clasificación.

Aplicaciones de Clasificación.

Detectar y resolver el desequilibrio de clases.

Principales modelos de Clasificación.

Métricas de evaluación: Clasificación.

Ejemplo práctico de un modelo de Clasificación.



Modelos supervisados de Clasificación

Algunos de los modelos de clasificación son:

- Support Vector Machines (SVM)
- K-nearest neighbors (k-NN)
- Árboles de decision
- Ensemble Random Forest
- Neural Network (MLP)







Support Vector Machines (SVM)

DEFINICIÓN: El objetivo de una SVM es encontrar un hiperplano óptimo que separe las clases, maximizando el margen entre dicho hiperplano y los puntos de cada clase mas cercanos.

VENTAJAS: Eficaz en espacios de alta dimensión. Utiliza de forma eficiente la memoria. Funciona bien con márgenes claros de separación.

DESVENTAJAS: Tiene bajo rendimiento cuando el número de características es mayor que el número de muestras. Menos eficiente en datasets grandes.








Support Vector Machines

¿Qué pasa cuando los datos no son separables linealmente?

SVM kernels: El uso de kernels en SVM es fundamental para trabajar con datos complejos y no lineales, y permite al modelo encontrar fronteras de decisión más flexibles y precisas.

- Los datos en forma de espiral no se pueden separar con una línea recta.
- El kernel RBF permite generar una frontera curva que separa las clases.



Al comparar dos kernels aplicados al mismo set de datos la frontera de decisión se adapta a la forma de los datos.




K-Nearest Neighbors (Vecinos más próximos K)

DEFINICIÓN : K-NN es un algoritmo de clasificación (también para regresión) que no entrena un modelo, sino que toma decisiones directamente a partir de los datos. Selecciona los k puntos más cercanos (vecinos) y asigna la clase más frecuente entre esos vecinos.

VENTAJAS : Sencillo de implementar y entender. Robusto ante datos con ruido si k (**vecinos cercanos**) se elige bien. Funciona bien con conjunto de datos pequeños y de baja dimension.

DESVENTAJAS : Lento en predicción, ya que compara con todos los puntos de entrenamiento. Requiere elegir un buen valor de k (No tan alto). Mala eficiencia en datos grandes.

Con $k=3$: se clasifica como cuadrado.
 Con $k=7$: se clasifica como triángulo.



K (ej. 1-3) $\downarrow$: Modelo muy sensible
(riesgo de sobreajuste).

K (ej. 15+) $\uparrow$: Más estable, puede ser impreciso y más costoso en CPU.




Árboles de decisión

DEFINICIÓN : Es un modelo que aprende reglas simples a partir de los datos. A partir de un conjunto de atributos y sus respectivas clases, el árbol genera una secuencia de decisiones que guían hasta una predicción.

VENTAJAS : Fácil de entender y visualizar (cada decisión es una regla clara). Entrenamiento y predicción rápida. Funciona bien con datos categóricos y numéricos.

DESVENTAJAS

Puede sobre ajustarse fácilmente si no se limita su profundidad o complejidad. Inestable, pequeños cambios en los datos pueden generar árboles muy decisiones.



Nodos internos: Condiciones de decision
Hojas: predicciones finales (clases)




Random Forest

DEFINICION: Es un algoritmo de ensamble que combina muchos árboles de decisión individuales para mejorar la precisión y estabilidad del modelo. Cada árbol hace su propia predicción y el resultado final se obtiene por votación mayoritaria

VENTAJAS: Reduce el sobreajuste en comparación con un solo árbol. Mayor precisión en la mayoría de los casos. Capaz de manejar grandes volúmenes de variables y seleccionar automáticamente las relevantes. Funciona bien con datos faltantes o ruidosos.

DESVENTAJAS : Predicción más lenta en tiempo real, ya que se deben consultar múltiples árboles.

EXAMPLES



- Cada árbol individual puede dar una predicción diferente.
- Tree-1 y Tree-2 votan por clase A.
- Tree-n vota por clase B
- El modelo elige la mas votada




Neural Network (MLP – Multilayer Perceptron)

DEFINICIÓN: Una red neuronal artificial es un modelo inspirado en el cerebro humano, compuesto por capas de nodos (neuronas artificiales) interconectados. Su estructura incluye, una capa de entrada, capas ocultas, capa de salida. Es como una “caja negra” que aprende a partir de muchos ejemplos.

VENTAJAS: Ideal para problemas complejos y no lineales. Escalable, funciona bien con grandes volúmenes de datos. Una vez entrenada, permite hacer predicciones rápidas y eficientes.

DESVENTAJAS: Entrenamiento costoso, requiere muchos datos, tiempo y capacidad computacional. Difícil de interpretar, es menos explicable que otros modelos.



Input layer: Recibe los datos de entrada (Imagen a píxeles).

Hidden Layer: Procesan la información internamente.



Output Layer: Devuelve la predicción final.



Neural Network (Funcion de activación)

- Las funciones de activación introducen no linealidad en la red y permiten que aprenda patrones complejos. Sin activación, la red sería equivalente a una regresión lineal.


Función	Características clave
Sigmoid	Salida entre 0 y 1. Útil para clasificación binaria.
ReLu	Rápida y eficiente. Funciona bien con redes profundas. (Es la más utilizada)
Tanh	Salida entre -1 y 1.





Neural Network (Batch, epoch e iteraciones)

Concepto	Definición breve
Batch	Es el numero de muestras que se usan en una sola iteración del modelo.
Epoch (época)	Es una pasada completa por todo el conjunto de batches.
Iteración	Es una actualización del modelo usando un batch.



37

Ejemplo. Cada epoch recorre todos los datos



TensorFlow Playground


Es una herramienta interactiva para visualizar cómo aprende una red neuronal. Permite experimentar sin necesidad de programar, ideal para entender conceptos como:

- Capas y neuronas
- Funciones de activación
- Tasa de aprendizaje (Learning rate)
- Regularización
- Overfitting
- Separación de clases

<http://playground.tensorflow.org/>



1. Barra de control: Learning rate controla los pasos de ajuste para reducir el error (ej. 0.001 (lento pero seguro) y ej. 0.1 (aprende rápido pero puede volverse inestable). Regularización ayuda a evitar el overfitting (L1, L2).
2. Panel de Datos: Elegir el tipo de datos (círculos, espirales, cluster, etc.), Ratio train/test, Ruido, cantidad de datos por iteración (Batch size), regenerate genera nuevo conjunto de datos aleatorios.
3. Features: Selección de variables de entrada siendo x_1 y x_2 coordenadas básicas. Transformaciones cuadráticas, senoidales, etc.
4. Arquitectura de la Red: Agregar o quitar capas ocultas y neuronas. Las líneas entre neuronas indican las conexiones (pesos). Color= Naranja (valor negativo), Azul (Valor positivo). Grosor = intensidad del peso. **(Aquí se puede experimentar).**
5. Output: Muestra cómo la red clasifica el espacio de entrada (zonas de colores) y errores de entrenamiento y prueba.





Actividad


Entender el efecto de la arquitectura y los parámetros.

1. Selecciona del database de espirales
2. Usa: 1 capa oculta con 4 neuronas, función de activación ReLu, Learning Rate de 0.03, Sin regularización
3. Pulsar PLAY
4. Observa: ¿Qué tan bien clasifica la red? ¿ Que pasa si agregan más capas o cambian la función de activación?

Preguntas adicionales: ¿Con qué configuración se logra menor error en test? ¿Qué pasa si se usa demasiadas neuronas?



Algoritmos Supervisados de Clasificación





Conceptos generales.

Tipos de Clasificación.

Aplicaciones de Clasificación.

Detectar y resolver el desequilibrio de clases.

Principales modelos de Clasificación.

Métricas de evaluación: Clasificación.

Ejemplo práctico de un modelo de Clasificación.



Evaluación de Algoritmos de Clasificación

Existen muchas formas de evaluar la precisión y desempeño del algoritmo.


Métricas de Clasificación

- Matriz de confusión
- Accuracy
- Recall
- Precisión
- MCC (Matthews correlation coefficient)
- Curva AUC-ROC



Matriz de confusión

Una matriz de confusión es una tabla que resume el rendimiento de un algoritmo de clasificación de tipo supervisado.



Acierto en la predicción

Predicted	Actual	
	Positive 1	Negative 0
Positive 1	True Positive	False Positive
Negative 0	False Negative	True Negative


- **Verdaderos positivos (TP):** Cuando predecimos un positivo y el resultado verdadero es positivo.
- **Falsos positivos (FP):** Cuando predecimos un positivo y el resultado verdadero es negativo.
- **Falsos negativos (FN):** Cuando predecimos un negativo y el resultado verdadero es positivo.
- **Verdaderos Negativos (TN):** Cuando predecimos un negativo y el resultado real es negativo.



Matriz de confusión

Una matriz de confusión es una tabla que resume el rendimiento de un algoritmo de clasificación de tipo supervisado.

		Actual	
		Positive 1	Negative 0
Predicted	Positive 1	True Positive	False Positive
	Negative 0	False Negative	True Negative



Objetivo: evitar falsos positivos y falsos negativos

- **Falsos positivos (FP):** Cuando predecimos un positivo y el resultado verdadero es negativo.
- **Falsos negativos (FN):** Cuando predecimos un negativo y el resultado verdadero es positivo.



Accuracy (exactitud)

Fracción de predicciones que se realizaron correctamente en un modelo de clasificación.

$$Accuracy = \frac{Total\ de\ aciertos\ (TP + TN)}{Total\ de\ muestras\ (N)} = \frac{270 + 9}{314} = 0,88$$

		Valor real		
		Actual - Cancer 1	Actual - NOT Cancer 0	Total
Predicciones	Predicted - Cancer 1	TP=9	FP=5	14
	Predicted - NOT Cancer 0	FN = 30	TN = 270	300
	Total	39	275	N=314

Matriz de confusion para el modelo de Hawkins

Pero... cuidado!

(Accuracy paradox)

Es necesario utilizar otras métricas de evaluación (recall, f1, etc).




Recall (Sensibilidad)

Número de predicciones de una clase que fueron correctamente identificadas entre el total de observaciones de esa clase.

Responde a la siguiente pregunta: *de todas las etiquetas positivas posibles, ¿cuántas identificó correctamente el modelo?*

Predicciones	Valor real		
	Actual - Cancer 1	Actual - NOT Cancer 0	Total
Predicted - Cancer 1	TP=9	FP=5	14
Predicted - NOT Cancer 0	FN = 30	TN = 270	300
Total	39	275	N=314




$$Recall = \frac{TP}{TP + FN} = \frac{9}{9 + 30} = 0,23$$



Precisión

Identifica la frecuencia con la que un modelo predijo correctamente la clase positiva.
 Responde a la siguiente pregunta: *de todas las predicciones que he etiquetado como cáncer, ¿cuántas eran realmente cáncer?*

	Valor real		Total
	Actual - Cancer 1	Actual - NOT Cancer 0	
Predicciones	Predicted - Cancer 1	TP=9 FP=5	14
	Predicted - NOT Cancer 0	FN = 30 TN = 270	300
Total	39	275	N=314



$$Precision\ Clase\ 1 = \frac{TP}{TP + FP} = \frac{9}{9 + 5} = 0,64$$



MCC (Matthews correlation coefficient)

Solo para **clasificación binaria**

MCC = 1 → Predicción perfecta
 MCC = 0 → Predicción aleatoria
 MCC = -1 → Predicción totalmente errónea

Valor real


Predicciones

	Actual - Cancer 1	Actual - NOT Cancer 0	Total
Predicted - Cancer 1	TP=9	FP=5	14
Predicted - NOT Cancer 0	FN = 30	TN = 270	300
Total	39	275	N=314

$$MCC = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} = 0,34$$




Curva ROC / AUC




Predicción perfecta.

- $AUC = 1$.
- $FPR=0$, $TPR=1$.




Predicción buena/mediocre.

- $AUC = (1-0,5)$
- Si AUC es 0.85, hay un 85% de probabilidades de que el modelo distinga correctamente las clases.



Predicción aleatoria.

- $AUC = 0,5$.
- $FPR=TPR$.
- Es tan exacto como voltear una moneda.
- ¡Este es el peor de los casos!



Predicción inversa.

- $AUC = 0$.
- $FPR=1$, $TPR=0$.
- El algoritmo predice perfectamente el inverso de las clases
- Situación altamente improbable.



Conceptos generales.

Tipos de Clasificación.

Aplicaciones de Clasificación.

Detectar y resolver el desequilibrio de clases.

Principales modelos de Clasificación.

Métricas de evaluación: Clasificación.

Ejemplo práctico de un modelo de Clasificación.




Ejercicio 2: Detección de cáncer de mama

- **Dataset:** Las características se calculan a partir de una imagen digitalizada de una aspiración con aguja fina (FNA) de una masa mamaria. Describen características de los núcleos celulares presentes en la imagen.

Atributos 30

radio (media):	6.981	28.11
textura (media):	9.71	39.28
perímetro (media):	43.79	188.5
área (media):	143.5	2501.0
suavidad (media):	0.053	0.163
compacidad (media):	0.019	0.345
concavidad (media):	0.0	0.427
puntos cóncavos (media):	0.0	0.201
simetría (media):	0.106	0.304
dimensión fractal (media):	0.05	0.097
radio (error estándar):	0.112	2.873
textura (error estándar):	0.36	4.885
perímetro (error estándar):	0.757	21.98
área (error estándar):	6.802	542.2
Suavidad (error estándar):	0.002	0.031
compacidad (error estándar):	0.002	0.135
concavidad (error estándar):	0.0	0.396
puntos cóncavos (error estándar):	0.0	0.053
simetría (error estándar):	0.008	0.079
dimensión fractal (error estándar):	0.001	0.03
radio (peor):	7.93	36.04
textura (peor):	12.02	49.54
perímetro (peor):	50.41	251.2
zona (peor):	185.2	4254.0
suavidad (peor):	0.071	0.223
compacidad (peor):	0.027	1.058
concavidad (peor):	0.0	1.252
puntos cóncavos (peor):	0.0	0.291
simetría (peor):	0.156	0.664
dimensión fractal (peor):	0.055	0.208

- N. Datos: 569 Datos
- N. Atributos: 30 atributos
- Clase:
 - 1. Maligno
 - 2. Benigno



•WN Street, WH Wolberg y OL Mangasarian. Extracción de características nucleares para el diagnóstico de tumores de mama. IS&T/SPIE 1993 Simposio internacional sobre imágenes electrónicas: ciencia y tecnología, volumen 1905, páginas 861-870, San José, CA, 1993.



Machine Learning y Deep Learning con Python

- Librerías para machine learning



- Fácil de utilizar (intuitivo)
- Contiene una amplia variedad de modelos de clasificación, regression, clustering y dimensional reduction.

<https://scikit-learn.org/stable/>

- Librerías para deep learning



Keras






Bibliografía

- **“Advanced Data Analytics for Power Systems”** - Ali Tajer, Samir M. Perlaza, H. Vincent Poor.
- **“Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems”** Aurelien Geron
- **“Python Data Science Handbook: Tools and Techniques for Developers: Essential Tools for working with Data”**. Jake VanderPlas



Más información

- [Cheat-sheets de Scikit-learn Machine Learning, Pandas, Matplotlib...](#)
- [Aprendizaje automático \(Coursera\)](#)



Pandas Cheat Sheet
Becoming Human AI

Pandas Data Structures

Pivot

Pivot Table

Multi

Advanced Indexing

Combining Data

Duplicate Data

Grouping Data

Missing Data

Visualization